

SOC 調査起点からの証跡付き行動列復元に向けた
CLOUSEAU 型ログ探索手法の評価
Evaluation of CLOUSEAU-based Log Investigation
for Evidence-backed Behavior Reconstruction from SOC Clues

著者名¹⁾ 共著者名²⁾
Author Name Coauthor Name

1 はじめに

Security Operation Center (SOC) におけるインシデント分析では、検知アラートを受け取った後に、端末上で実際に何が起きたかを説明可能な形で再構成する必要がある。アラート名や短い検知理由は調査の入口として有用である一方、それだけでは親子プロセス、コマンドライン、ファイル・レジストリ・ネットワーク操作、それらを支えるログ行の対応関係を十分に説明できない。調査者が最終的に必要とするのは、単なる悪性・良性のラベルではなく、観測証跡に基づき、どの主体が、どの対象に、どの順序で操作したかを示す行動列である。

本研究が対象とするのは、マルウェア検知そのものではなく、検知後のエンドポイント調査である。特に、SOC が少数の手がかりから調査を開始する状況を想定する。入力、EDR の alert 要約、または host, process, time window 程度の process/time clue であり、出力は証跡付きの行動ステップ列である。この設定では、CLOUSEAU のような LLM 階層型調査エージェント [1] が、自然言語の手がかりから探索方針を作り、SQLite 化されたログに対して反復的に問い合わせを行うことで、関連する観測行を集められる可能性がある。しかし、アラート理由を言い換えただけの出力、近傍の無関係な行動の混入、証跡で支えられない推定、行動順序の誤りが生じる危険もある。

本稿では、ATLASv2 benign H1 / benign-1 由来の Windows ホストログを用い、23 個の良性セキュリティ行動 chain を対象に、CLOUSEAU を基盤とするエージェント型ログ探索手法を評価する。ここで既存研究との立ち位置を明確にしておく。CLOUSEAU は、Point-of-Interest (POI) から攻撃調査を開始し、Chief Inspector, Investigator, Question-Answering agent が協調して attack narrative を復元する階層型 multi-agent framework である [1]。ATLAS は audit log から攻撃ストーリーを復元する攻撃調査支援手法であり [5]、ATLASv2 はその攻撃エンゲージメントと通常業務活動を拡張したデータセットである [6]。本研究は CLOUSEAU や ATLAS を置き換える攻撃調査アルゴリズムではない。CLOUSEAU の調査パイプラインと ATLASv2 のログ環境を用い、SOC の検知後調査を模した行動列復元ベンチマークとして、アラート要約への依存度、低レベル telemetry からの復元可能性、証跡同定の成否を測る研究である。

本稿の貢献は次の 3 点である。第一に、CLOUSEAU の POI 起点調査を SOC の検知後行動復元へ読み替え、行動 item, critical evidence, sequence order, candidate

precision, overclaim に分解した評価枠組みとして定義する。第二に、MITRE ATT&CK と LOLBA を参考に実務上調査対象になり得る process を選び、CBC alert で偽陽性として現れた時刻窓から 23 usecase を作る。これらを 3 段階の入力条件で実行し、アラート支援条件、process/time clue 条件、アラート要約行を隠した telemetry 中心条件を比較する。第三に、ATLASv2 由来の単一 Windows 良性環境における検知後分析として射程を限定し、明示的実行チェーン、複数段ツールチェーン、意味解釈型チェーンごとの失敗傾向を分析する。

2 関連研究

2.1 検知後調査としての行動列復元

エンドポイント調査では、Windows Security ログ、Sysmon, EDR telemetry, DNS, ブラウザ履歴など、粒度や記録目的の異なるログを横断する。Sysmon はプロセス生成、親プロセス、コマンドライン、ネットワーク接続、レジストリ操作などを記録できる [2]。EDR は検知理由やプロセス情報をまとめた alert summary を提供する場合がある。これらは調査に有用だが、alert summary は観測された全行動を代表するものではない。したがって、最終出力はアラート文面ではなく、ログ上で確認できる行動主張に限定する必要がある。

本研究の課題は、異常検知モデルの精度評価ではない。DeepLog のような系列異常検知研究は、ログ系列から異常を検出・診断することに焦点を置く [3]。一方、本研究は検知後の SOC 調査において、調査者が検証可能な証跡付き行動列を復元できるかを問う。この違いは評価単位にも表れる。本研究では自然文の類似度ではなく、主体、操作、対象、コマンドライン、証跡行などの必須 item を採点する。

2.2 LLM エージェントによるログ探索

LLM エージェントは、初期手がかりから仮説を立て、外部環境への問い合わせ結果に応じて次の探索を変更できる。ReAct は推論と行動を交互に進める枠組みを示しており [4]、ログ調査でも、時刻範囲、プロセス木、ファイル・レジストリ対象を段階的に確認する流れと親和性がある。

セキュリティ分野では、CLOUSEAU が階層型 multi-agent による自律的な攻撃調査を提案している [1]。CLOUSEAU は、raw incident logs を LLM が扱いやすい構造化形式へ変換し、QA agent を通じてログを自然言語的に検索可能にする。さらに、Investigator agent と Chief Inspector agent が調査 lead の生成、証跡収集、attack story の統合を行う。本研究はこの設計思想に基づくが、評価対象を「攻撃 story 全体の復元」から「SOC アラートや process/time clue 周辺の良性を含む行動 chain の証跡付き復元」へ移す。そのため、最終判定の正否ではなく、観測ログで支えられた行動 item と過剰主張を採点する。

1) 所属名,

Affiliation

2) 所属名,

Affiliation

2.3 ATLAS/ATLASv2 の位置づけ

ATLAS は、audit log に基づいて攻撃ストーリーを復元するため、因果依存グラフと系列学習を組み合わせた攻撃調査支援手法である [5]。ATLASv2 は、ATLAS の攻撃シナリオを再現しつつ、通常業務活動と Sysmon および Carbon Black Cloud 由来のログを拡充したデータセットとして報告されている [6]。本研究では、ATLASv2 を「攻撃検知済みの答えを読むデータ」ではなく、「SOC でアラートや telemetry を受け取った後、端末上の行動を証跡付きで説明する能力を測るデータ」として利用する。この立ち位置により、本研究の対象インシデント分析は、侵害全体の帰属や最終判定ではなく、アラート周辺の端末行動復元であると明確化される。

3 提案手法

3.1 パイプライン

図 1 に、本研究で用いる CLOUSEAU 型のエージェント型ログ探索パイプラインを示す。入力は、CBC alert rows、または host/process/time window である。CLOUSEAU 本来の POI 起点調査 [1] にならい、Chief agent は初期手がかりから調査方針を生成する。Investigation agent は、確認すべき事実を QA Agent / SQL expert への質問に変換する。QA Agent / SQL expert は、SQLite 化されたエンドポイントログに問い合わせ、timestamp、source stream、PID/PPID、process tree、command line、registry path、source row idなどを返す。Final synthesis は観測結果を統合し、主行動列、補助証跡、limitations を出力する。




図 1 SOC 調査起点から証跡付き行動列を復元するパイプライン

本手法の設計上の要点は、仮説生成と観測ログ検索を分離することである。Chief agent は直接 SQL を書かず、Investigation agent が観測済みの値に基づいて次の確認事項を作る。DB に問い合わせるのは QA Agent / SQL expert であり、Final synthesis は観測行で支えられる行動だけを主系列に含める。これにより、alert name や reason の言い換えを行動復元と誤認しないようにする。

3.2 出力と評価単位

出力は、steps、sequence、evidence、nearby、limitations からなる。steps は主体、操作、対象、コマンドライン、証跡を持つ主行動ステップである。sequence は観測された操作を短く並べた系列であり、アラート名ではなくログ上の操作を表す。evidence は source stream、row id、timestamp、PID、command line などの根拠である。nearby は時刻や対象に近いが主系列に含めない行動を明示する。

採点では、gold chain を行動 item に分解する。必須 item は、ログから直接確認できる主体、操作、対象、コマンドライン、critical evidence である。観測行だけ

から主張できない悪性判定、ユーザ意図、業務目的、ファイル内容の推定は必須 item に含めない。候補出力の主張は正規化され、gold item と照合される。主指標は、行動 item recall、critical evidence recall、sequence order、candidate claim precision、overclaim slot count である。

4 実験設定

4.1 データと chain

実験には、ATLASv2 benign H1 / benign-1 環境を CLOUSEAU のログ探索形式へ変換した Windows ホストログを用いた。評価単位は 23 個の behavior chain である。usecase は、単にログ中の行を機械的に切り出したものではなく、実務上 SOC で調査対象になり得る process を起点に選定した。まず、MITRE ATT&CK や LOLBA を参考に、攻撃でも正常運用でも使われ得る Windows 上の process や一般ツールを候補化した。次に、ATLASv2 内の CBC alert で実際に良性環境中に検知された時刻窓を抽出し、CBC alert、focus process、周辺 telemetry から一つの行動背景を説明できるものを chain 化した。この手順により、CBC alert を起点に SOC 調査が始まるが、最終的には良性行動として説明すべき 23 usecase を得た。

chain は、DNS packet capture batch、Python Simple-HTTPServer network、Sublime Python script execution、cmd.exe 周辺操作、Discord Run Key registry の 5 種類の raw chain type から構成される。分析時には、これらを明示的実行チェーン、複数段ツールチェーン、意味解釈型チェーンの 3 群にまとめる。表 1 に、usecase の内訳を示す。

表 1 usecase 選定結果

行動背景	Chains	Group
Python 簡易 Web サーバ	13	明示的実行
DNS/通信ログ収集 batch	5	複数段ツール
Sublime 経由 Python 実行	2	複数段ツール
cmd.exe 周辺操作	2	明示的実行
Discord Run key 登録	1	意味解釈

明示的実行チェーンは、親子プロセスとコマンドラインが比較的直接的に観測できる chain である。複数段ツールチェーンは、batch、packet capture tool、editor、script、file/network side effect など、複数の道具や中間ステップを結ぶ必要がある chain である。意味解釈型チェーンは、Discord/Update.exe と Run Key のように、アプリケーション固有またはレジストリ固有の意味解釈を必要とする chain である。

4.2 3 段階の入力条件

表 2 に、3 つの stage を示す。Stage 1 は CBC alert rows を入力に含めるアラート支援条件である。Stage 2 は host、focus process、time window のみを入力とし、DB 内には alert summary rows を残す。Stage 3 は Stage 2 と同じ初期入力だが、検索対象から CBC alert summary rows を除外する。ただし、CBC EDR/NGAV event telemetry、Security、Sysmon、DNS、browser history は残す。

この設計により、初期入力の強さと、DB 内の高密度なアラート要約行の有無を分けて観察できる。Stage 2 と Stage 3 の差は、alert summary が最終出力として使わ

表2 入力条件

Stage	入力	意味
Stage 1	CBC alert rows	アラート支援の復元
Stage 2	host/process/time	DB 内の要約行は利用可能
Stage 3	host/process/time	alert summary rows を検索対象から除外

れるかではなく、探索経路や証跡同定の足場として機能するかを調べるためのものである。

4.3 実行と採点

表3に、本稿で用いる評価系列を整理する。正式な性能比較に用いるのは、23 chain, 3 stage, 3 set からなる各モデル 207 run である。3 set のうち2つは23 chain として実行した replicate であり、残る1つは旧 27 chain 実行から同じ 23 chain ID だけを抽出した set である。gpt-5.5 は 23 chain, 3 stage の 69 run を実行したが、構造化 JSON 契約を満たさない raw text 出力を後処理で salvage したため、正式比較とは分けて扱う。

表3 評価系列と母数

Use	Chains	Stages	Sets	Runs
正式比較	23	3	3	207/model
5.5 raw	23	3	1	69

正式比較の対象は gpt-4.1-mini と gpt-5.4-mini である。各モデルについて、23 chain を 3 stage で 3 set 評価し、207 run を得た。2 モデル合計で 414 run を採点し、gpt-5.5 は 69 run の raw text salvage として別枠で確認した。採点対象の gold は、起点となる観測行の特定、process action または object operation への分解、必須 item 定義、critical evidence slot 固定、gold chain に属さない近傍行動の除外という手順で作成した。

採点では、単に似た説明文が出ているかではなく、行動を構成する最小単位がログ証跡に接続しているかを重視した。たとえば、“Python が実行された”という説明だけでは、主体、実行対象、親子関係、コマンドライン、時刻のいずれを根拠としているかが曖昧である。そこで各 step を、主体、操作、対象の action item に分け、それとは独立に、該当 step を支える critical evidence item を定義した。この分離により、モデルが行動の概略を当てたが証跡を示せない場合と、証跡行を拾ったが行動列として整理できない場合を区別できる。sequence order は、隣接する gold step の前後関係が候補出力で保たれた割合として数えた。

また、候補出力の品質を見るため、candidate claim precision と overclaim も記録した。candidate claim precision は、モデルが主張した候補 claim のうち gold chain に対応するものの割合である。overclaim は、近傍イベント、時刻窓内に存在するが主系列ではない操作、または証跡からは断定できない因果関係を、chain の一部として述べた件数である。SOC 調査支援では広めの候補提示が有用な場面もあるため、overclaim をただちに失敗とは見なさない。しかし、本研究で評価したいのは「証跡に基づく行動列復元」であるため、正解 item を多く拾う

recall だけでなく、主系列と補助情報の境界をどれだけ保てるかを併せて評価した。

本稿の 23 chain 集計では、各 stage あたり 65 behavior steps を基準とし、1 set では 3 stage 合計 195 step, 3 set 合計では 585 step を評価する。各 step は主体、操作、対象の3つの action item と、1つの critical evidence item を持つ。したがって、正式比較の分母は各モデルについて action item が 1755, critical evidence が 585, order が 378 である。なお、第3 set は旧 27 chain 実行から現在の 23 chain に対応する行だけを抽出したものであり、完全な新規 replicate ではない。この点は、3 set 平均の分散解釈に制約を与える。

採点は単一の自動 judge だけで確定しない。候補出力と gold を並べたレビュー行を作成し、2回の独立レビューを行い、一致した項目を採用した。判断が割れた項目は conflict queue へ入れ、追加レビューまたは保守的な採択で確定した。表の値は、表現や JSON field の完全一致ではなく、必要な内容が候補出力に含まれるかを見る content inclusion 方針で集計した。

4.4 評価範囲と除外条件

本研究の評価範囲は、alert または process/time clue を起点として、端末上の具体的な行動 chain を復元することである。マルウェア分類、攻撃キャンペーン attribution, MITRE ATT&CK technique label の推定、検知ルールの良い評価は主目的ではない。この限定は、ATLASv2 と CLOUSEAU を利用する本研究の立ち位置を明確にするためである。ATLASv2 は攻撃調査に近いログ環境を提供し、CLOUSEAU は POI から証跡を探索して narrative を組み立てる枠組みを与える。本稿はその上で、SOC がアラート後に行う「何が起きたかを証跡付きで説明する」作業に対象を絞る。

除外したものも明示しておく。第一に、出力が最終的に悪性か良性かを判定できたかは採点しない。対象 chain には良性操作が含まれるため、悪性判定を正解とする評価は本研究の目的とずれる。第二に、長い自然文として読みやすいかは補助的に確認するが、主指標にはしない。読みやすい報告書であっても、証跡 ID やイベント行に接続できなければ SOC の検証対象としては不十分である。第三に、Stage 3 は alert summary rows を隠す条件であり、すべての EDR telemetry を取り除く条件ではない。このため、Stage 3 の結果は、低レベルログだけで常に十分であることではなく、高密度な summary を欠いても残存 telemetry から復元可能な部分があることを示す。

公開用パッケージには、case metadata, chain summary, gold index, run ごとのモデル出力 JSON, 採点 rubric, 集計 CSV/JSON を含めた。一方、元の incident.db, scenario.db, EVTX, 外部データセット本体は含めない。したがって、本稿の表と run-level 挙動は検査可能であるが、完全な再実行にはローカルの ATLASv2/CLOUSEAU データベース環境が必要である。

5 結果と考察

5.1 全体結果

表4に、全体結果を示す。gpt-5.4-mini は 207 run 全体で行動 item recall 79.8% (1400/1755), critical evidence recall 70.3% (411/585) を示した。一方、gpt-4.1-mini は行動 item recall 46.6% (818/1755), critical evidence recall

19.5% (114/585) であった。この比較は 23 chain の 3 set 集計であり、第 3 set に旧 27 chain 実行からの 23 chain 抽出を含む点に注意が必要である。

表 4 全体結果

Model	Action	Crit. ev.	Order
gpt-4.1-mini	46.6%	19.5%	20.1%
gpt-5.4-mini	79.8%	70.3%	55.3%

注目すべき点は、gpt-5.4-miniでも candidate claim precision は 58.4%に留まったことである。これは、強いモデルが正解 item を多く拾える一方で、候補出力に近傍行動や重複主張も残すことを意味する。SOC 支援としては広めに候補を出す価値があるが、論文上の行動列復元としては、主系列と補助証跡の分離が依然として課題である。

表 5 に、claim quality の補助指標を示す。gpt-4.1-mini は candidate precision が 36.6%で、overclaim が 1190 件であった。一方、gpt-5.4-miniは candidate precision を 58.4%まで改善し、overclaim も 651 件まで減らした。ただし、半数近い候補 claim が gold chain に直接対応しない点が残っている。この結果は、LLM が調査文脈で有用な候補生成器になり得る一方、そのまま最終報告書として使うには、claim の昇格・棄却を制御する仕組みが必要であることを示す。

表 5 候補 claim 品質

Model	Precision	Overclaim
gpt-4.1-mini	36.6%	1190
gpt-5.4-mini	58.4%	651

この差は、単なる表現力の差だけでは説明しにくい。gpt-4.1-miniは、時刻窓内に存在するイベントを広く拾い、それらを chain の一部として結合しがちであった。これに対して gpt-5.4-miniは、親子プロセス、ファイルパス、コマンドライン、引数、通信先などの証跡を比較して、主系列らしい候補を選ぶ傾向が強かった。しかし、Stage 3 や複数段ツールチェーンでは、packet capture tool の実行、script file の編集、HTTP server 起動、browser access などが時刻的に近接するため、主系列と周辺操作を完全に分けることは難しい。この点が、recall の高さ と precision の伸び悩みが同時に現れる理由である。

5.2 Stage 別結果

表 6 に Stage 別結果を示す。gpt-5.4-miniは Stage 1 で 79.1% (463/585)、Stage 2 で 80.0% (468/585)、Stage 3 で 80.2% (469/585) の行動 item recall を示した。23 chain 最終集計では各 stage の分母を揃えており、Stage 3 だけ小さい分母で見せてはいない。したがって、alert summary rows を隠した条件でも、残存 telemetry から同程度の action item を復元できたと読める。

一方で、gpt-5.4-miniの Stage 2/3 の order は 54.0%であり、Stage 1 の 57.9%よりやや低い。process/time clue だけで探索を開始する場合、必要な item に到達できても、それらを正しい順序または因果的構造として並べることは難しい。Stage 3 では claim precision が 59.4%で維持された一方、overclaim は 223 件であり、候補主張の量は依

表 6 Stage 別結果 (23 chain, 3 set)

Model	Stage	Action	Crit. ev.
4.1-mini	S1	63.9%	29.2%
4.1-mini	S2	41.4%	12.8%
4.1-mini	S3	34.5%	16.4%
5.4-mini	S1	79.1%	57.4%
5.4-mini	S2	80.0%	75.4%
5.4-mini	S3	80.2%	77.9%

然として多い。alert summary がない条件では、低レベル telemetry を広く探索するため、主系列に含めるべき行動と近傍行動の境界が曖昧になりやすい。

表 7 に、gpt-5.4-miniの Stage 別 order と claim precision を示す。Stage 1 では alert rows が起点と順序の足場を与えるため、order は 57.9%であった。Stage 2 では、DB 内に alert summary rows が残っているにもかかわらず、入力が host/process/time clue へ弱まることで order が 54.0%となった。つまり、探索対象に summary が存在すること、最初から alert 文脈が入力されることは等価ではない。Stage 3 でも order は 54.0%であり、precision は 59.4%であった。これは、summary を検索できないことで、モデルが低レベル証跡に寄った順序付けを試みる一方、候補 claim を多めに保持するためと考えられる。

表 7 gpt-5.4-miniの Stage 別補助指標

Stage	Order	Precision	Overclaim
S1	57.9%	55.9%	215
S2	54.0%	59.7%	213
S3	54.0%	59.4%	223

この結果から、alert summary rows には少なくとも二つの働きがあると解釈できる。第一に、調査開始時の意味的な手掛かりとして、どの process や object を中心に見るべきかを制限する働きである。第二に、探索途中で発見した低レベルイベントを、chain のどの位置に置くかを決める境界条件としての働きである。Stage 2 は後者を利用できるが前者が弱く、Stage 3 は両者のうち summary 由来の足場をさらに失う。そのため、Stage 3 で recall が高くても、それは summary 不要という意味ではない。むしろ、summary がない場合には、候補 claim の剪定と順序制約がより重要になることを示している。

5.3 Scenario 別結果

表 8 に gpt-5.4-miniの scenario group 別結果を示す。明示的実行チェーンでは action recall 86.5%、critical evidence recall 82.4%、order 76.4%であり、親子プロセスやコマンドラインが直接観測できる chain では高い性能を示した。複数段ツールチェーンでは action recall 74.6%を示したが、order は 43.1%、claim precision は 46.9%に低下した。意味解釈型チェーンは 1 chain を 3 stage、3 set で評価した 9 run のみであり、数値は傾向の示唆に留まる。その範囲では、critical evidence recall 48.1%、order 33.3%となり、registry/app 固有の意味解釈が難所である可能性を示した。

表8 gpt-5.4-miniの scenario 別結果

Group	Action	Crit. ev.	Order
明示的実行	86.5%	82.4%	76.4%
複数段ツール	74.6%	60.2%	43.1%
意味解釈	64.2%	48.1%	33.3%

5.4 gpt-5.5 と運用コスト

gpt-5.5については、正式な JSON 契約を満たした 207 run の 3 set 採点結果がないため、表 4 の正式比較には含めない。23 chain に対する raw text salvage では高い復元傾向が見られたが、raw text から後処理で claim を抽出した単一 replicate であり、正式 JSON 評価とは同列に扱えない。したがって、本稿では gpt-5.5 を性能結論ではなく、出力契約と費用制御を改善した次実験の候補として位置づける。

表 9 に、運用コストと実行時間の補助集計を示す。gpt-5.5 low raw は、69 run で入力 1.83M tokens、出力 0.73M tokens を消費し、推定費用は 31.00 USD であった。平均実行時間は 9.32 分で、直列合計は 10.72 時間、4 並列相当では 2.68 時間である。gpt-5.4-mini の補助ログは 207 run で 4.35 USD、平均 2.05 分であり、費用・時間の両面で軽い。したがって、gpt-5.5 は復元品質の上限を探る参照点として有用だが、出力契約失敗と高い出力 token 費用を考えると、全量実験の標準モデルとしては扱いにくい。

表9 モデル別コスト・token・時間

Model	Runs	Cost	Tok.	Avg min
4.1-mini	207	\$3.64	7.40M	6.81
5.4-mini	207	\$4.35	2.67M	2.05
5.5 raw	69	\$31.00	2.56M	9.32

今後 gpt-5.5 を正式採用するには、少数 pilot で JSON 契約、max output tokens、累積費用停止条件を確認してから、23 chain × 3 stage × 3 set の同一 rubric で再実行する必要がある。

5.5 考察

本研究の結果は、CLOUSEAU と ATLASv2 を組み合わせることで、検知後の端末行動復元を評価できることを示している。CLOUSEAU は攻撃 narrative 復元のための階層型調査エージェントであり、ATLAS/ATLASv2 は攻撃調査文脈のデータ・手法として位置づけられてきた。本研究では、CLOUSEAU の POI 起点探索を SOC のアラート後分析に引き寄せ、ATLASv2 のログ環境上で、検知ラベルの分類ではなく、アラートや process/time clue からログ証跡で支えられた行動 chain を構成する能力を測った。

良性 chain を対象にした点も重要である。SOC では、悪性攻撃だけでなく、管理操作、開発作業、ツール実行、アプリケーション更新なども調査対象になる。これらはアラートを発生させたり、攻撃手法に似た telemetry を持ったりする。したがって、良性行動を証跡付きで説明できることは、誤検知低減や調査記録作成に直結する。

Stage 1 はアラート情報を入力に含み、Stage 2 は入力から外すが DB には残し、Stage 3 は検索対象から alert summary rows を隠す。Stage 3 で gpt-5.4-mini が分母を揃

えた条件でも高い recall を示したことは、出力が alert summary の単純な言い換えではなく、残存 telemetry から多くの行動 item を復元できたことを示す。ただし、Stage 3 でも overclaim は残るため、alert summary は探索の近道や境界設定として機能していた可能性がある。

5.6 CLOUSEAU との差分

本研究は CLOUSEAU に強く依存しているため、CLOUSEAU との違いを曖昧にすると、貢献が見えにくくなる。CLOUSEAU は、POI を起点として Chief Inspector, Investigator, QA agent が協調し、攻撃 narrative を再構成する階層型 multi-agent framework である。本稿はこの枠組みを、攻撃キャンペーン全体の narrative 復元ではなく、SOC のアラート後調査で頻出する短い behavior chain 復元に適用し、入力条件と評価粒度を変えて検証した。特に、良性 chain を含む点、Stage 1-3 で alert summary の有無を分ける点、action item と critical evidence item を分離して採点する点が異なる。

この違いは、研究目的の違いでもある。CLOUSEAU の主眼は、攻撃を説明する narrative をエージェントが構築できるかである。本研究の主眼は、SOC 調査者が最終判断を行う前段として、モデルがログ上の行動単位と根拠行をどれだけ正確に揃えられるかである。そのため、本稿では自然文としてもっとも説得的な story よりも、gold step, critical evidence, order, overclaim を重視した。これは、実運用のインシデント分析では、華麗な説明よりも、後から検証可能な証跡列が必要になるためである。

5.7 失敗傾向

失敗は三つに整理できる。第一は、近傍イベントの巻き込みである。同じ時刻窓に複数の管理操作や開発作業が存在すると、モデルはそれらを一つの chain に結合しやすい。これは Stage 3 で特に目立ち、alert summary による境界が消えると、関連しそうな低レベルイベントを広く残す傾向が強まる。

第二は、意味解釈型 chain での根拠不足である。Discord/Update.exe と Run Key registry のような chain では、プロセス名やレジストリパスの意味を理解する必要がある。単にイベント行を拾うだけでは、永続化、更新処理、アプリ固有挙動のどれとして読むべきかが決まらない。このため、critical evidence recall と order がともに低下した。

第三は、順序と因果の混同である。ログ上の時刻順は、行動の因果順と一致するとは限らない。特に、ファイル作成、プロセス起動、ネットワーク接続、DNS query が短時間に発生する chain では、モデルが観測順をそのまま因果順として述べる場合があった。この問題を解くには、単なる検索結果の列挙ではなく、親子関係、object identity, command line argument, network endpoint を束ねる制約付きの synthesis が必要である。

5.8 実用上の含意

実用上、本結果は LLM を単独の自動判定器として使うよりも、調査者が確認すべき候補 chain を作る補助器として使う方が現実的であることを示す。gpt-5.4-mini は、多くの正解 item と critical evidence を拾えるため、初動調査の探索範囲を狭める用途に向く。一方で、candidate precision が 58.4% である以上、出力をそのままインシデント報告書へ転記する設計は危険である。モデ

ル出力は、証跡行、主系列 claim、補助 claim、棄却候補に分け、調査者が昇格判断を行う UI や workflow と組み合わせる必要がある。

また、Stage 3 の結果は、アラート summary が失われた環境でも一定の復元が可能であることを示すが、summary を不要化できることを意味しない。むしろ、summary は調査対象を狭め、overclaimを抑え、順序を安定させる補助情報として有用である。SOC における望ましい運用は、alert summary を根拠として鵜呑みにすることではなく、summary を起点に低レベル telemetry へ降り、モデルに再構成させた chain を再び証跡で検証する循環である。

6 おわりに

本稿では、CLOUSEAU を基盤とするエージェント型ログ探索手法により、SOC 調査起点から Windows エンドポイントログを探索し、証跡付き行動列を復元する課題を、ATLASv2 benign H1 / benign-1 由来の 23 behavior chain で評価した。gpt-5.4-mini は 207 run 全体で行動 item recall 79.8%、critical evidence recall 70.3%を示した。alert summary rows を隠した Stage 3 でも、分母を揃えた条件で 80.2%の行動 item recall を示した。一方で、candidate claim precision、overclaim、sequence order には課題が残った。

本研究の立ち位置は、CLOUSEAU の攻撃 narrative 復元をそのまま再評価するものでも、ATLAS/ATLASv2 を用いた攻撃検知評価でもなく、検知後の SOC インシデント分析における行動列復元評価である。今後は、SQL 探索履歴の分析、主系列昇格条件の強化、順序制約を持つ synthesis、意味解釈型 chain の拡充により、調査者がそのまま検証できる行動 story の品質を高める。

本評価の限界として、対象は単一の ATLASv2 benign 環境から構成した 23 chain であり、組織横断の SOC ログや攻撃キャンペーン全体を代表するものではない。また、Stage 3 は alert summary rows のみを検索対象から除外する条件であり、EDR telemetry 全体を除外した条件ではない。このため、本稿の結論は「alert summary なしでも一定の行動復元が可能」という範囲に留め、「任意の低レベルログだけで十分」とは主張しない。

妥当性への脅威は五点ある。第一に、gold chain の作成はログ構造と実験目的を理解した上で行っており、完全に自動的な正解ではない。このため、step 境界の切り方や critical evidence slot の選び方に、作成者の判断が入る。本稿では、主体、操作、対象、根拠行を分けて定義し、23 chain 最終集計では stage 間の分母を揃えることで、恣意的な高得点化を避けた。第二に、評価対象の chain は良性環境に由来するため、攻撃者が意図的に痕跡を隠すケース、複数ホストへ横展開するケース、長時間に分散するキャンペーンは含まれていない。したがって、本結果は攻撃調査全体の代替ではなく、単一ホス

トのアラート後分析に近い短い chain 復元の結果として読む必要がある。第三に、本稿には単発 LLM や単純時刻窓検索とのベースラインがなく、CLOUSEAU 型パイプライン自体の上乗せ効果は分離できていない。第四に、API version、temperature、top-p、seed、プロンプト全文などの再現情報は公開パッケージ側に依存しており、本文中には十分に収められていない。第五に、本稿の比較は二つのモデルに限られる。特に、gpt-5.5については raw text salvage の補助結果とコスト・token・時間の記録を示したが、同一 rubric で採点済みの 23 chain × 3 stage × 3 set 正式 JSON 結果ではない。未採点または分母の異なる結果を正式比較へ混ぜると、モデル比較として不正確になるためである。ただし、gpt-5.5が高い復元率を示した点は、出力契約と費用制御を改善した次実験の有力な候補であることを示す。

今後の実装では、モデル出力を一つの文章として受け取るのではなく、claim graph として扱う。各 claim に、対応する event row、親子 process 関係、object identity、時刻範囲、confidence、gold chain 候補への対応を付与し、主系列 claim と補助 claim を明示的に分ける。その上で、調査者が claim を採用、保留、棄却できる UI を用意すれば、高 recall な探索と人間による precision 改善を両立できる。また、CLOUSEAU の QA agent に相当する検証段を、単なる自然文批評ではなく、未接続 claim、証跡不足 claim、順序矛盾 claim を検出する形式へ拡張することが有効である。これにより、Stage 3 で顕在化した overclaim を、報告書生成前に抑制できる可能性がある。

参考文献

1. A. Aldaihan, F. Alotaibi, and S. Maffei, “Clouseau: A Hierarchical Multi-Agent Approach For Autonomous Attack Investigation,” 2025. <https://www.doc.ic.ac.uk/~maffeis/papers/acsac25.pdf>
2. Microsoft, “Sysmon - Sysinternals,” <https://learn.microsoft.com/en-us/sysinternals/downloads/sysmon> (参照 2026-06-09).
3. M. Du, F. Li, G. Zheng, and V. Srikumar, “DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning,” Proc. ACM CCS, pp. 1285–1298, 2017.
4. S. Yao, J. Zhao, D. Yu, N. Du, I. Shafraan, K. Narasimhan, and Y. Cao, “ReAct: Synergizing Reasoning and Acting in Language Models,” arXiv:2210.03629, 2022.
5. A. Alsaheel, Y. Nan, S. Ma, L. Yu, G. Walkup, Z. B. Celik, X. Zhang, and D. Xu, “ATLAS: A Sequence-based Learning Approach for Attack Investigation,” Proc. USENIX Security, pp. 3005–3022, 2021.
6. A. Riddle, K. Westfall, and A. Bates, “ATLASv2: ATLAS Attack Engagements, Version 2,” arXiv:2401.01341, 2023.