

SOC 調査起点からの証跡付き行動列復元に向けた CLOUSEAU 型ログ探索エージェントの評価

Evaluation of CLOUSEAU-style Log Investigation Agents for Evidence-backed Behavior

Reconstruction from SOC Clues

小松崎大世¹

¹ 北海道大学大学院情報科学院

1 はじめに

SOC (Security Operation Center) におけるインシデント分析では、検知アラートを受け取った後に、端末上で実際に何が起きたかを説明可能な形で再構成する必要がある。アラート名や検知理由は調査の入口として有用である一方、それだけでは親子プロセス、コマンドライン、ファイル・レジストリ・ネットワーク操作、それらを支えるログ行の対応関係を十分に説明できない。調査者が最終的に必要とするのは、「怪しい」というラベルではなく、観測証跡に基づいて、どの主体が、どの対象に、どの順序で操作したかを示す行動列である。

本研究が対象とするのは、マルウェア検知そのものではなく、検知後のエンドポイント調査である。入力、CBC alert の要約、または host, process, time window 程度の process/time clue であり、出力は証跡付きの行動ステップ列である。この設定では、CLOUSEAU のような LLM 階層型調査エージェント [1] が、自然言語の手がかりから探索方針を作り、SQLite 化されたログに対して反復的に問い合わせを行うことで、関連する観測行を集められる可能性がある。しかし、アラート理由を言い換えただけの出力、近傍の無関係な行動の混入、証跡で支えられない推定、行動順序の誤りが生じる危険もある。

本稿では、ATLASv2 由来の Windows ホストログを用い、23 個の良性セキュリティ行動 chain を対象に、CLOUSEAU を基盤とするエージェント型ログ探索手法を評価する。ここで既存研究との立ち位置を明確にしておく。CLOUSEAU は、Point-of-Interest (POI) から攻撃調査を開始し、Chief Inspector, Investigator, Question-Answering agent が協調して attack narrative を復元する階層型 multi-agent framework である [1]。ATLAS は audit log から攻撃ストーリーを復元する攻撃調査支援手法であり [5]、ATLASv2 はその攻撃エンゲージメントと通常業務活動を拡張したデータセットである [6]。本研究は CLOUSEAU や ATLAS を置き換える攻撃調査アルゴリズムではない。CLOUSEAU の調査パイプラインと ATLASv2 のログ環境を用い、SOC の検知後調査を模した行動列復元ベンチマークとして、アラート要約への依存度、低レベル telemetry からの復元可能性、証跡同定の成否を測る研究であ

る。

本稿の貢献は次の 3 点である。第一に、CLOUSEAU の POI 起点調査を SOC の検知後行動復元へ読み替え、action component, critical evidence, sequence order, candidate precision, overclaim に分解した評価枠組みとして定義する。第二に、23 chain を 3 段階の入力条件で評価し、アラート支援条件、process/time clue 条件、アラート要約行を隠した telemetry 中心条件を比較する。第三に、gpt-4.1-mini, gpt-5.4-mini, および raw-output salvage 条件である gpt-5.5 low raw を比較し、精度、過剰主張、コスト、出力契約違反の観点から SOC 支援における実用上の境界を整理する。

2 関連研究と課題設定

2.1 検知後調査としての行動列復元

エンドポイント調査では、Windows Security ログ, Sysmon, EDR telemetry, DNS, ブラウザ履歴など、粒度や記録目的の異なるログを横断する。Sysmon はプロセス生成、親プロセス、コマンドライン、ネットワーク接続、レジストリ操作などを記録できる [2]。EDR は検知理由やプロセス情報をまとめた alert summary を提供する場合がある。これらは調査に有用だが、alert summary は観測された全行動を代表するものではない。したがって、最終出力はアラート文面ではなく、ログ上で確認できる行動主張に限定する必要がある。

本研究の課題は、異常検知モデルの精度評価ではない。DeepLog のような系列異常検知研究は、ログ系列から異常を検出・診断することに焦点を置く [4]。一方、本研究は検知後の SOC 調査において、調査者が検証可能な証跡付き行動列を復元できるかを問う。この違いは評価単位にも表れる。本研究では自然文の類似度ではなく、主体、操作、対象、コマンドライン、証跡行などの必須 item を採点する。

2.2 LLM エージェントによる探索

LLM エージェントは、初期手がかりから仮説を立て、外部環境への問い合わせ結果に応じて次の探索を変更できる。ReAct は推論と行動を交互に進める枠組みを示しており [3]、ログ調査でも、時刻範囲、プロセス木、ファイル・レジストリ対象を段階的に確認する流れと親和性がある。CLOUSEAU は、raw incident

logs を LLM が扱いやすい構造化形式へ変換し、QA agent を通じてログを検索可能にし、Investigator agent と Chief Inspector agent が調査 lead の生成、証跡収集、attack story の統合を行う [1]。本研究はこの設計思想に基づくが、評価対象を「攻撃 story 全体の復元」から「SOC アラートや process/time clue 周辺の良性を含む行動 chain の証跡付き復元」へ移す。

2.3 ATLASv2 の利用範囲

ATLASv2 は、攻撃エンゲージメントと通常業務活動を含むログデータセットである [6]。本研究では、ATLASv2 を「攻撃検知済みの答えを読むデータ」ではなく、「SOC でアラートや telemetry を受け取った後、端末上の行動を証跡付きで説明する能力を測るデータ」として利用する。対象は、DNS packet capture, Python SimpleHTTPServer, Sublime 経由の script execution, cmd.exe 周辺操作, Discord Run Key 関連操作など、良性環境内でもセキュリティアラートや調査対象になり得る行動である。

3 提案手法

3.1 パイプライン

図 1 に、本研究で用いる CLOUSEAU 型のエージェント型ログ探索パイプラインを示す。入力は、CBC alert rows, または host/process/time window である。CLOUSEAU 本来の POI 起点調査 [1] にならい、Chief agent は初期手がかりから調査方針を生成する。Investigation agent は、確認すべき事実を QAAgent / SQL expert への質問に変換する。QAAgent / SQL expert は、SQLite 化されたエンドポイントログに問い合わせ、timestamp, source stream, PID/PPID, process tree, command line, registry path, source row id などを返す。Final synthesis は観測結果を統合し、主行動列、補助証跡、limitations を出力する。

3.2 出力と評価単位

本研究では、最終出力を行動ステップ単位で評価する。各 gold step は、主体、操作、対象からなる action component と、その step をログから支える critical evidence を持つ。さらに、隣接する gold step の順序関係を sequence order として評価する。モデル出力が gold 内容を実質的に含めば hit とし、表現の違いは許容する。一方、alert name や alert reason を行動そのものとして出した場合、gold chain に属さない近傍行動を主系列として含めた場合、証跡で支えられない推定を含めた場合は、candidate claim precision の分母または overclaim として扱う。

4 実験設定

4.1 データと chain

対象は ATLASv2 由来ログから構成した 23 behavior chain である。各 chain は、起点となる観測行、対象ホスト、focus process、time window、gold behavior steps、critical evidence slots を持つ。旧 27-chain 実験から、現在の評価対象として妥当な 23 chain を採用し、gold は CBC alert summary だけを根拠にしない形へ統一

した。これにより、Stage 3 で alert summary rows を隠した場合でも、残存 telemetry から回答可能な範囲を評価できる。

chain は大きく 3 種類に分ける。明示的実行チェーンは、プロセス名、コマンドライン、ネットワーク接続、レジストリ操作が直接観測される行動であり、詳細分類では `network_service_behavior` と `command_shell_execution` を含む。複数段ツールチェーンは、tshark, batch, Sublime, cmd, Python など複数のプロセスやツールをまたぐ行動であり、`collection_or_tool_invocation` と `script_execution_chain` を含む。意味解釈型チェーンは `persistence_registry_run_key`, すなわち Discord Run Key の 1 chain であり、レジストリ永続化の意味づけを含むため、カテゴリ全体の結論ではなく case study として扱う。

4.2 3 段階の入力条件

表 1 に、3 つの stage を示す。Stage 1 は CBC alert rows を入力に含めるアラート支援条件である。Stage 2 は host, focus process, time window のみを入力とし、DB 内には alert summary rows を残す。Stage 3 は Stage 2 と同じ初期入力だが、検索対象から CBC alert summary rows を除外する。ただし、CBC EDR/NGAV event telemetry, Security, Sysmon, DNS, browser history は残す。

この設計により、初期入力の強さと、DB 内の高密度なアラート要約行の有無を分けて観察できる。Stage 3 は CBC 全体を除外する条件ではない。CBC alert summary rows のみを検索対象から外し、CBC EDR/NGAV telemetry は残す。したがって、本稿の結論は「alert summary なしでも一定の行動復元が可能」という範囲に留め、「任意の低レベルログだけで十分」とは主張しない。

4.3 実行と採点

比較対象は gpt-4.1-mini, gpt-5.4-mini, および gpt-5.5 low raw である。各モデルについて 23 chain, 3 stage, 3 set 相当を評価し、各モデル 207 rows を得た。gpt-4.1-mini と gpt-5.4-mini の第三セットは、同一条件で新規実行した formal23 replicate ではなく、旧 27-chain 実験から現在の 23-chain 対象だけを抽出した実質第三セットである。gpt-5.5 low raw は 3 セット完了しているが、要求した JSON/code_steps 出力契約に従わなかったため、raw-output salvage として採点した。

採点は Codex 内の複数レビューにより、component rubric で行った。各 run は 2 つの独立レビューを基本とし、判定が割れた場合は第三レビューで裁定した。主指標は、action component recall, critical evidence recall, behavior sequence order, candidate claim precision, overclaim slot count である。CBC alert-summary-only evidence は non-alert critical evidence として数えない。gpt-5.5 low raw は内容包含に基づく実質的な復元能力を見るために採点対象としたが、構造化出力に従った gpt-4.1-mini/gpt-5.4-mini と完全に同じ運




Figure 1: SOC 調査起点から証跡付き行動列を復元するパイプライン

Table 1: 3 段階の入力条件

Stage	入力	意味
Stage 1	CBC alert + process/time	アラート支援の復元
Stage 2	process/time のみ	DB 内の要約行は利用可能
Stage 3	process/time のみ	alert summary rows を SQL 検索対象から除外

用条件とはみなさない。

表の数値は公開パッケージ内の最終 ledger を基準とし、`overall.csv`、`by_stage.csv`、`by_scenario_group.csv` から作成した。

5 結果

5.1 全体結果

表 2 に、全体結果を示す。構造化出力を満たした範囲では、`gpt-5.4-mini` が `gpt-4.1-mini` を大きく上回った。action recall は 0.466 から 0.798 へ、critical evidence recall は 0.195 から 0.703 へ、order は 0.201 から 0.553 へ上昇し、overclaim は 1190 から 651 へ減少した。これは、モデル更新により単なる説明生成だけでなく、証跡接続と順序構成が改善したことを示す。

`gpt-5.5 low raw` は action recall 0.918, critical evidence recall 0.906, order 0.868 と最も高い復元能力を示した。一方で、overclaim は 1235 と最大であり、かつ出力契約に失敗した。したがって、`gpt-5.5 low raw` は「潜在的な行動復元能力の上限」を示す結果として扱うべきであり、そのまま最良の運用設定と結論づけるべきではない。SOC 支援では、高い recall だけでなく、指定スキーマに従うこと、主系列と近傍証跡を分けること、過剰主張を抑えることが必要である。

5.2 Stage 別結果

表 3 に Stage 別結果を示す。`gpt-5.4-mini` は Stage 1 から Stage 3 まで action recall が 0.791, 0.800, 0.802 とほぼ一定であり、critical evidence recall は Stage 3 で 0.779 と最も高い。これは、alert summary rows を隠しても、残存 telemetry から多くの行動と証跡を復元できることを示す。`gpt-5.5 low raw` も全 Stage で action/evidence recall が 0.90 以上であり、Stage 差は小さい。

この結果の解釈では注意が必要である。Stage 3 で性能が維持されたことは、alert summary が不要であ

ることを意味しない。Stage 3 でも CBC EDR/NGAV telemetry は残っており、モデルはそこから process, registry, network などの証跡へ到達できる。正しい主張は、alert summary rows が唯一の復元経路ではなく、十分に強いモデルでは non-alert telemetry から復元可能な場合がある、ということである。

5.3 Scenario 別結果

表 4 に scenario group 別結果を示す。明示的実行チェーンは、少なくとも強いモデルにおいて、証跡回収と順序構成が最も安定した成功領域であり、`gpt-5.4-mini` で evidence recall 0.824, `gpt-5.5 low raw` で 0.975 に達した。これらはプロセス名、コマンドライン、ネットワーク接続、レジストリ操作が直接観測されるため、gold behavior とログ証跡を対応づけやすい。scenario group は、明示的実行チェーンが `network_service_behavior` と `command_shell_execution`、複数段ツールチェーンが `collection_or_tool_invocation` と `script_execution_chain`、意味解釈型が `persistence_registry_run_key` に対応する。

複数段ツールチェーンは難しい。`gpt-5.4-mini` では action recall 0.746 に対して order が 0.431, claim precision が 0.469 まで下がる。これは、個々の観測行を拾う能力と、複数ツールをまたぐ主系列として順序づける能力が別問題であることを示す。`gpt-5.5 low raw` は multi-step でも order 0.796 まで改善するが、overclaim は 421 残る。意味解釈型は Discord Run Key の 1 chain, 9 scored rows のみであり、広いカテゴリ結論ではなく、レジストリ永続化の case study として扱う。

5.4 コストと実行上の含意

表 5 にコスト効率を示す。`gpt-4.1-mini` と `gpt-5.4-mini` は local ledger と local price estimate に基づく集計であり、`gpt-5.5 low raw` は local ledger

Table 2: 23-chain 最終比較の全体結果

Model	Runs	Action	Crit. ev.	Order	Claim prec.	Overclaim
gpt-4.1-mini	207	0.466	0.195	0.201	0.366	1190
gpt-5.4-mini	207	0.798	0.703	0.553	0.584	651
gpt-5.5 low raw	207	0.918	0.906	0.868	0.640	1235

Table 3: Stage 別結果

Model	Stage	Action	Crit. ev.	Order	Claim prec.	Overclaim
gpt-4.1-mini	Stage 1	0.639	0.292	0.341	0.433	422
gpt-4.1-mini	Stage 2	0.414	0.128	0.111	0.285	506
gpt-4.1-mini	Stage 3	0.345	0.164	0.151	0.382	262
gpt-5.4-mini	Stage 1	0.791	0.574	0.579	0.559	215
gpt-5.4-mini	Stage 2	0.800	0.754	0.540	0.597	213
gpt-5.4-mini	Stage 3	0.802	0.779	0.540	0.594	223
gpt-5.5 low raw	Stage 1	0.937	0.908	0.897	0.658	374
gpt-5.5 low raw	Stage 2	0.915	0.908	0.857	0.620	415
gpt-5.5 low raw	Stage 3	0.903	0.903	0.849	0.643	446

の `call_total_usd` がゼロ記録だったため、公開パッケージ内の `cost audit note` に基づく保守的推定である。 `gpt-5.4-mini` は `gpt-4.1-mini` より総コストはわずかに高いが、復元精度の改善が大きいため、 `cost per evidence hit` と `cost per order hit` はむしろ低い。一方、 `gpt-5.5 low raw` は最も高い精度を示すが、207 run の保守的推定コストは約 93.52 ドルであり、 `cost per evidence hit` と `cost per order hit` は大きく増える。

このため、本実験の運用上の結論は、単純に最高精度モデルを選ぶことではない。構造化出力を満たし、低コストで安定した改善を示す `gpt-5.4-mini` が現時点の最も現実的な選択肢である。 `gpt-5.5 low raw` は、raw text からの salvage 採点では強いが、出力契約違反と高コストを考えると、そのまま大規模実験や実運用へ展開するには制約が大きい。なお、 `gpt-5.5 low raw` の金額は `cost audit note` に基づく再構成推定であり、請求額そのものとしては扱わない。

6 考察

6.1 ATLASv2 上で何を評価できたか

本研究が評価したのは、ATLASv2 上の良性行動 chain に対して、SOC 調査起点から証跡付き行動列を復元する能力である。したがって、結果はマルウェア検知率や攻撃キャンペーン全体の再構成率を意味しない。むしろ、検知後調査の局面で、アラートや process/time clue からログ探索を始め、調査者が確認可能な behavior story をどの程度作れるかを測ったものである。この設定は、CLOUSEAU の POI 起点調査を、SOC の検知後説明生成へ転用する際の評価ベンチマークとして位置づけられる。

6.2 アラート要約の役割

Stage 3 で `gpt-5.4-mini` と `gpt-5.5 low raw` が大きく崩れなかったことは重要である。alert summary rows を検索対象から除外しても、CBC EDR/NGAV telemetry や OS 側ログに残る process, command line, registry, network evidence から復元できる chain が多い。これは、最終出力が alert summary の単純な言い換えでは

ないことを示す。

一方で、alert summary は探索の近道や境界設定として機能していた可能性がある。特に、対象プロセス、対象レジストリ、検知理由が要約された行は、主系列候補を絞る索引として働く。Stage 3 で `gpt-5.5 low raw` の overclaim が 446 まで増えたことは、強いモデルでも、低レベル telemetry を広く探索するほど、主系列と近傍行動の境界が曖昧になりやすいことを示す。

6.3 モデル強化で解ける問題と残る問題

モデル強化は、証跡回収と順序構成の両方に効く。 `gpt-5.4-mini` は `gpt-4.1-mini` に比べて evidence recall を大きく改善し、 `gpt-5.5 low raw` はさらに order を 0.868 まで引き上げた。これは、複数ログソースを横断して、process tree や registry/network 操作を統合する能力がモデル規模に依存することを示す。

しかし、precision と overclaim は別の問題として残る。 `gpt-5.5 low raw` は最も正しい部品を拾う一方で、最も多くの overclaim を出した。この傾向は、LLM が調査文脈を広く推測し、周辺証跡や類似行動も主系列に含めやすいことを示す。したがって、今後は単に強いモデルへ置き換えるだけでなく、出力 schema の強制、evidence gating, nearby evidence の別枠化、SQL 履歴に基づく post-processing が必要である。

6.4 妥当性への脅威

第一に、対象は単一の ATLASv2 由来環境から構成した 23 chain であり、組織横断の SOC ログや攻撃キャンペーン全体を代表するものではない。第二に、 `gpt-4.1-mini` と `gpt-5.4-mini` の第三セットは旧 27-chain run を 23-chain scope へ抽出したものであり、完全な同一条件 replicate ではない。第三に、 `gpt-5.5 low raw` は raw-output salvage であり、構造化出力契約に従った比較ではない。第四に、Stage 3 は alert summary rows のみを検索対象から除外する条件であり、EDR telemetry 全体を除外した条件ではない。第五に、採点は content-inclusion matching を用いる component-rubric judgment であり、完全に機械的な自

Table 4: Scenario group 別結果

Model	Scenario	Chains	Action	Crit. ev.	Order	Claim prec.	Overclaim
gpt-4.1-mini	explicit	15	0.501	0.237	0.243	0.351	734
gpt-4.1-mini	multi-step	7	0.428	0.158	0.176	0.382	416
gpt-4.1-mini	semantic	1	0.506	0.148	0.167	0.444	40
gpt-5.4-mini	explicit	15	0.865	0.824	0.764	0.640	345
gpt-5.4-mini	multi-step	7	0.746	0.602	0.431	0.469	288
gpt-5.4-mini	semantic	1	0.642	0.481	0.333	0.719	18
gpt-5.5 low raw	explicit	15	0.978	0.975	0.972	0.609	787
gpt-5.5 low raw	multi-step	7	0.851	0.839	0.796	0.673	421
gpt-5.5 low raw	semantic	1	0.988	0.889	0.889	0.802	27

Table 5: コスト効率の概算 (4.1/5.4 は local ledger 推定, 5.5 は progress 側再構成推定)

Model	Total	Avg/run	/evidence	/order
gpt-4.1-mini	\$3.64	\$0.0176	\$0.0320	\$0.0479
gpt-5.4-mini	\$4.35	\$0.0210	\$0.0106	\$0.0208
gpt-5.5 low raw	\$93.52	\$0.4518	\$0.1764	\$0.2851

然言語一致ではない。2 レビューと衝突時の第三レビューで揺れを抑えたが、非盲検のローカルレビューであること、23 chain に対する集計で信頼区間や有意差検定を示していないこと、モデル版・価格が変動し得ることは妥当性上の制約である。これらを踏まえ、本稿の結論は「SOC 調査起点からの証跡付き行動列復元におけるモデル・stage・scenario の傾向」として読むべきである。

7 おわりに

本稿では、CLOUSEAU を基盤とするエージェント型ログ探索手法により、SOC 調査起点から Windows エンドポイントログを探索し、証跡付き行動列を復元する課題を、ATLASv2 由来の 23 behavior chain で評価した。構造化出力を満した **gpt-5.4-mini** は、**gpt-4.1-mini** に比べて action recall, critical evidence recall, sequence order を大きく改善し、overclaim も減らした。raw-output salvage としての **gpt-5.5 low raw** は最も高い復元能力を示したが、出力契約違反、過剰主張、高コストという制約を持つ。また、Stage 3 でも強いモデルは多くの行動を復元でき、alert summary rows は唯一の復元経路ではないことが示された。今後は、出力 schema の強制、主系列と近傍証跡の分離、SQL 履歴を用いた探索経路分析、および複数環境への拡張に取り組む。

References

- [1] Y. H. Lee, C. M. Choi, H. J. Kim, and D. H. Lee, “CLOUSEAU: A Hierarchical Multi-Agent Framework for Automated Attack Investigation,” arXiv:2505.01799, 2025.
- [2] Microsoft, “Sysmon - Sysinternals,” <https://learn.microsoft.com/en-us/sysinternals/downloads/sysmon> (参照 2026-06-09).
- [3] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, “ReAct: Synergiz-

ing Reasoning and Acting in Language Models,” arXiv:2210.03629, 2022.

- [4] M. Du, F. Li, G. Zheng, and V. Srikumar, “DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning,” Proc. ACM CCS, pp. 1285–1298, 2017.
- [5] A. Alsaheel, Y. Nan, S. Ma, L. Yu, G. Walkup, Z. B. Celik, X. Zhang, and D. Xu, “ATLAS: A Sequence-based Learning Approach for Attack Investigation,” Proc. USENIX Security, pp. 3005–3022, 2021.
- [6] A. Riddle, K. Westfall, and A. Bates, “ATLASv2: ATLAS Attack Engagements, Version 2,” arXiv:2401.01341, 2023.